Modèle de fondation pour l'EEG : pré-entraînement JEPA

Yanic ROTHLINGSHOFER

Télécom Paris

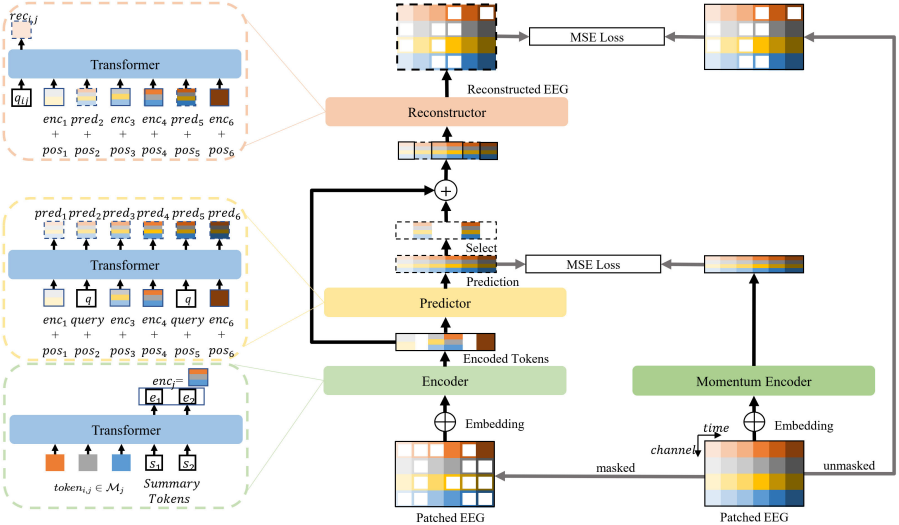
Supervisor : Van Tam Nguyen

Plan

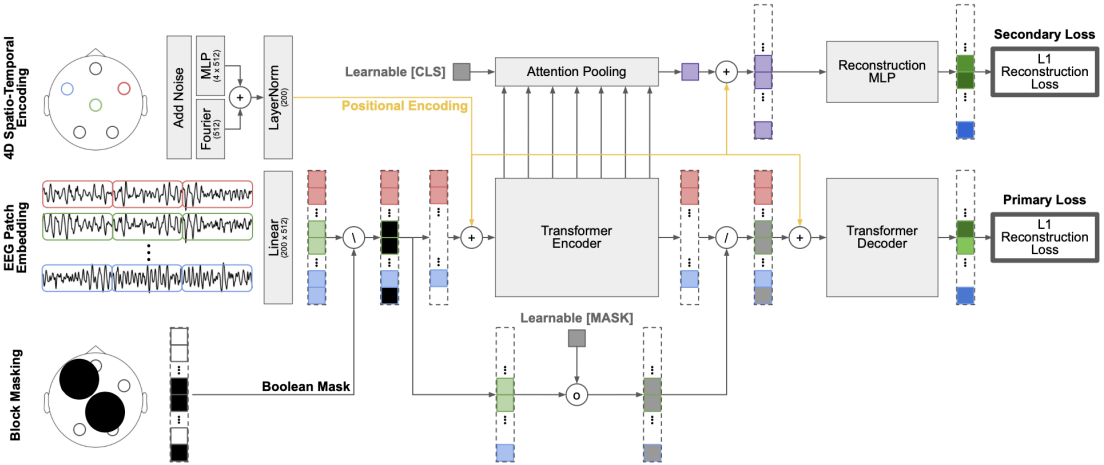
1. Modèles de fondation pour l'EEG
2. Paradigmes de pré-entraînement
3. Résultats et analyse

Modèles de fondation pour l'EEG

EEGPT — masquage spatio-temporel et double objectif

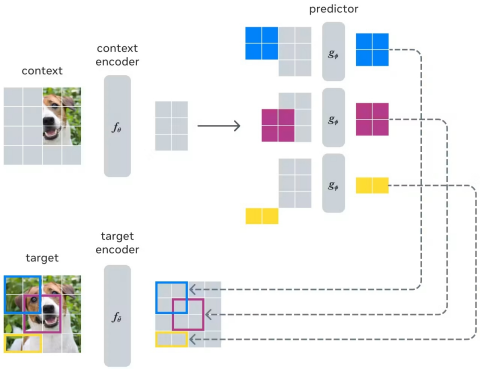


REVE — encodage spatio-temporel 4D et montages hétérogènes



Paradigmes de pré-entraînement

I-JEPA — prédiction dans l'espace des représentations



Un *context encoder* f_θ encode un bloc de contexte ; un *target encoder* $f_{\bar{\theta}}$ (EMA de f_θ) encode plusieurs blocs cibles. Un *predictor* g_ϕ, conditionné par les tokens de position des cibles, prédit leurs représentations :

$$\mathcal{L}_{\text{I-JEPA}} = \sum_b \left\| g_\phi(f_\theta(x_{\text{ctx}}),\, p_b) - \text{sg}\left[f_{\bar{\theta}}(x_b)\right] \right\|_2^2$$

- ✓ Pas de reconstruction pixel/signal : cible sémantique, pas de détail haute fréquence.
- ✓ Pas de paires négatives, pas d'augmentations lourdes.
- ✗ Anti-collapse purement *architectural* : EMA + `stop-grad` + asymétrie.
- ✗ Beaucoup d'hyperparamètres couplés (momentum, taille des blocs, *warm-up*).

LeJEPA — 1. perte d'alignement

Mise en place. Un **seul** encodeur f_θ, ni EMA, ni *predictor*, ni `stop-grad`. Pour chaque signal x_i du batch on tire V vues globales et L vues locales (bruit, échelle globale et par canal, décalage temporel, masques temps / fréquence / canaux) :

$$z_i^{(u)} = f_\theta\big(x_i^{(u)}\big) \in \mathbb{R}^D, \qquad u = 1, \dots, V{+}L$$

($z_i^{(u)} = z_{\text{glob}}$, la sortie *attention pooling* du bottleneck.)

Objectif. Toutes les vues d'un même signal doivent converger vers le centre de ses vues globales :

$$c_i = \frac{1}{V} \sum_{v=1}^{V} z_i^{(v)}, \qquad \mathcal{L}_{\text{align}} = \frac{1}{B\,(V{+}L)\,D} \sum_{i=1}^{B} \sum_{u=1}^{V+L} \big\| z_i^{(u)} - c_i \big\|_2^2$$

- Le centre c_i n'utilise que les vues *globales* : les vues locales sont tirées vers elles, jamais l'inverse.
- c_i n'est pas détaché $\Rightarrow$ le gradient circule dans toutes les vues (aucune asymétrie).
- Seule, cette perte est minimisée par la solution triviale $z \equiv \text{const}$: d'où la régularisation.

LeJEPA — 2. perte de régularisation (SIGReg)

Objectif. Forcer la distribution des z *dans le batch* à être une gaussienne isotrope $\mathcal{N}(0, I_D)$. Test fait sur des projections 1D (*sketching*) : S directions $\theta_s \sim \mathcal{U}(\mathbb{S}^{D-1})$, puis comparaison de la fonction caractéristique empirique de $\langle \theta_s, z \rangle$ à celle de la gaussienne, $e^{-t^2/2}$:

$$\hat{\varphi}_s(t) = \frac{1}{B} \sum_{i=1}^{B} e^{\mathrm{i}\, t \,\langle \theta_s, z_i \rangle}, \qquad \mathcal{L}_{\text{SIGReg}} = \frac{1}{S} \sum_{s=1}^{S} B \int_{-5}^{5} \left| \hat{\varphi}_s(t) - e^{-t^2/2} \right|^2 \underbrace{e^{-t^2/2}}_{\text{poids}} \, \mathrm{d}t$$

Objectif total, un unique hyperparamètre λ :

$$\mathcal{L} = (1 - \lambda)\, \mathcal{L}_{\text{align}} + \lambda\, \mathcal{L}_{\text{SIGReg}}, \qquad \lambda = 0.05$$

- En pratique : $S = 256$ directions, intégrale par trapèzes sur 17 points de $[-5, 5]$, calculée en `float32` et sommée sur les GPU en DDP.
- Directions retirées à chaque pas depuis `base_seed`+`global_step` : identiques sur tous les rangs, mais renouvelées à chaque itération.
- Appliquée séparément à chaque vue, puis moyennée sur les $V+L$ vues.

LeJEPA — pourquoi ce choix

Avantages

- ✓ Anti-collapse *explicite* : SIGReg interdit toute distribution dégénérée, plus besoin d'EMA, de `stop-grad` ni de *predictor*.
- ✓ Un seul hyperparamètre de perte (λ).
- ✓ La gaussienne isotrope est le prior qui minimise le risque du *probing* linéaire en aval.
- ✓ Coût $\mathcal{O}(B\,S\,P)$ par vue : négligeable devant l'encodeur.

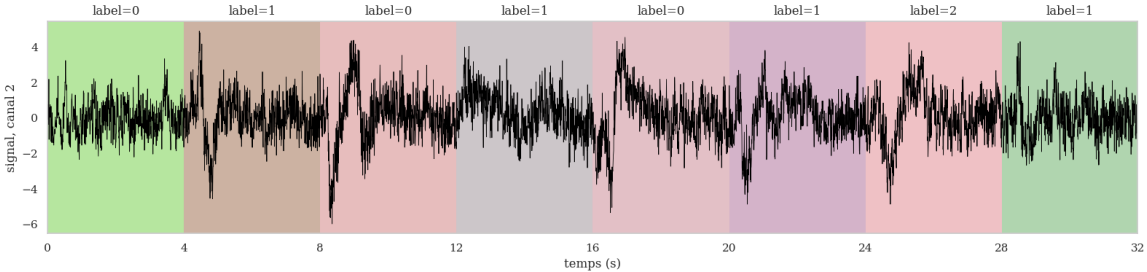
Limites / points de vigilance

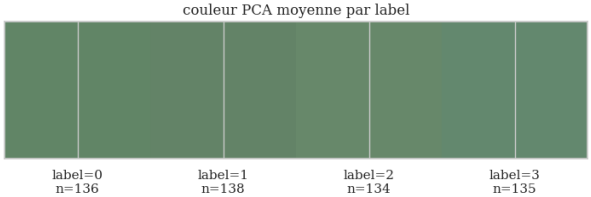
- ✗ SIGReg est une statistique *sur le batch* : elle exige un batch large (à $B = 4$ le latent collapse).
- ✗ Les vues doivent rester informatives : des gains d'augmentation nuls annulent la diversité des vues globales.
- ✗ Invariance imposée par les augmentations : si elles effacent l'information de tâche, elle disparaît du latent.

Valeurs de référence en régime sain : $\mathcal{L}_{\text{SIGReg}} \approx 1.06$, $\mathcal{L}_{\text{align}} \approx 1.17$.

Résultats et analyse

Analyse du latent global par PCA — BCI2A (imagerie motrice, 4 classes)





Comparaison aux modèles de l'état de l'art — balanced accuracy (%)

Modèle	#params (M)	BCI2A	PHYSIONETMI	FACED	SLEEPEDF	TUAB
CBraMod	–	–	–	–	–	–
CSBrain	–	–	–	–	–	–
EEGMamba	–	–	–	–	–	–
EEGPT	–	–	–	–	–	–
LaBraM	–	–	–	–	–	–
REVE	–	63.62	**63.01**	**54.42**	–	–
LuMamba	–	–	–	–	–	–
LUNA	–	–	–	–	–	–
EEG-FM (ours)	–	–	–	–	–	–
EEGNet *(baseline)*	–	**72.66**	60.46	49.67	–	–